

Aa2) 1.)

Beh: $\max \left| \frac{\partial h_n}{\partial w_i} \right| = |h_{n-1}| \cdot \frac{1}{4}$

Bew: Sigmoid $\sigma(x) = \frac{1}{1+e^{-x}}$

kettenregel
 $\sigma'(x) = \frac{e^{-x}}{(1+e^{-x})^2} = \frac{1}{1+e^{-x}} \cdot \frac{e^{-x}}{1+e^{-x}} = \sigma(x) \cdot \frac{1+e^{-x}-1}{1+e^{-x}}$
 $= \sigma(x) \cdot (1 - \sigma(x))$

Substitution: $\sigma(x) = t$, $t \in (0,1)$ da $0 < \frac{1}{1+e^{-x}} < 1$

$\Rightarrow g(t) = t(1-t) \Rightarrow g'(t) = 1-2t \stackrel{!}{=} 0$

$\Rightarrow 1-2t = 0 \Rightarrow t = \frac{1}{2}$

$g''(t) = -2 < 0 \Rightarrow t = \frac{1}{2}$ ist ein Maximum von

$g(t)$

$g(\frac{1}{2}) = \frac{1}{2} \cdot (1 - \frac{1}{2}) = \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}$

$\sigma'(x) = \sigma(x)(1-\sigma(x)) = g(\sigma(x))$

$\Rightarrow \max_x \sigma'(x) = \max_{t \in (0,1)} g(t) = g(\frac{1}{2}) = \frac{1}{4}$

$\Rightarrow \forall j: |\sigma'(w_j h_{j-1})| \leq \frac{1}{4}$ und nach Annahme

$|w_j| < 1$

Laut Aa 1) gilt $\frac{\partial h_n}{\partial w_i} = \prod_{j=i+1}^n [\sigma'(w_j h_{j-1}) w_j]$

$\cdot \sigma'(w_i h_{i-1}) \cdot h_{i-1}$

$\Rightarrow \left| \frac{\partial h_n}{\partial w_i} \right| \leq \left(\prod_{j=i+1}^n \left(\frac{1}{4} \cdot \overbrace{|w_j|}^{< 1} \right) \right) \cdot \frac{1}{4} \cdot |h_{i-1}|$

$\leq \left(\frac{1}{4} \right)^{n-(i+1)} \cdot 1 \cdot \frac{1}{4} \cdot |h_{i-1}|$

$= \frac{1}{4}^{n-i+1} |h_{i-1}|$

Maximalwert über i findet man für $i=n$:

$|h_{n-1}| \left(\frac{1}{4} \right)$. (Für große Tiefe n geht der Term

$\left(\frac{1}{4} \right)^{n-i+1}$ stark gegen 0.

□

Aa2) 2.)

ReLU $\sigma(x) = \max(0, x)$

$\sigma'(x) = \begin{cases} 1 & \text{für } x > 0 \\ 0 & \text{sonst} \end{cases}$

$\Rightarrow \frac{\partial h_n}{\partial w_i} \stackrel{\text{Formel aus Aa 1)}}{=} \left(\prod_{j=i+1}^n w_j \right) h_{i-1}$

Da $|w_j| < 1$ schrumpft $\prod_{j=i+1}^n w_j$, aber es gibt keinen zusätzlichen Faktor, der schrumpft.

Der Maximalwert über i liegt bei $i=n$: $\frac{\partial h_n}{\partial w_n} = h_{n-1}$